

# Rapport de projet statistique inférentielle en R

## Table of contents

<b>1</b>	<b><i>Exercice 1 : Algorithme en R</i></b>	<b>1</b>
<b>2</b>	<b><i>Exercice 2 : Influence de l'alcool sur le temps de réaction</i></b>	<b>3</b>
<b>3</b>	<b><i>Exercice 3 : Analyse de données pour enfant</i></b>	<b>8</b>

## **1 Exercice 1 : Algorithme en R**

1. Calculer la moyenne et la variance d'une série statistique des données entrées par un utilisateur

- Première du code :
  - On demande à l'utilisateur de saisir l'effectif de la série statistique
  - On initialise un vecteur 'numeric' de la longueur spécifiée
  - On demande de saisir les différents éléments de la série statistique

```

1 #=====
2 #                               Exercice 1
3 #
4 #=====
5
6
7 # Demander à l'utilisateur la taille de la série
8 n <- as.integer(readline("Entrez l'effectif de la série : "))
9
10 # Initialiser un vecteur vide
11 serie <- numeric(n)
12
13 # Lire les éléments un par un
14 for (i in 1:n) {
15   serie[i] <- as.numeric(readline(paste("Entrez la valeur numéro", i, ": ")))
16 }
17

```

2. Resultat de la première partie du code

```

> # Demander à l'utilisateur la taille de la série
> n <- as.integer(readline("Entrez l'effectif de la série : "))
Entrez l'effectif de la série : 5
> # Initialiser un vecteur vide
> serie <- numeric(n)
> # Lire les éléments un par un
> for (i in 1:n) {
+   serie[i] <- as.numeric(readline(paste("Entrez la valeur numéro", i, ": ")))
+ }
Entrez la valeur numéro 1 : 0.60
Entrez la valeur numéro 2 : 0.80
Entrez la valeur numéro 3 : 0.78
Entrez la valeur numéro 4 : 0.45
Entrez la valeur numéro 5 : 0.90
>

```

- Seconde partie du code :
  - On calcul la moyenne de la série puis on l'affiche
  - On calcul la variance de l'échantillon ()

```

18
19
20 # Calcul de la moyenne
21 moyenne <- mean(serie)
22
23 # Affichage du résultat
24 cat("La moyenne de la série est :", moyenne, "\n")
25
26 # Variance de l'échantillon
27 variance_echantillon = var(serie)
28 cat("La variance de l'échantillon est de: ", variance_echantillon, "\n")
29
30 # Calcul de la variance de la population ( $S^2$ )
31 variance_population <- var(serie) * (n - 1) / n
32 # Affichage de la valeur de la variance de la série statistique
33 cat("La variance de la population est de : ", variance_population, "\n")
34

```

### 3. Résultat du code


```

> # Calcul de la moyenne
> moyenne <- mean(serie)
> # Affichage du résultat
> cat("La moyenne de la série est :", moyenne, "\n")
La moyenne de la série est : 0.706
> cat("La variance de l'échantillon est de: ", variance_echantillon, "\n")
La variance de l'échantillon est de: 3.2
> # Calcul de la variance de la population ( $S^2$ )
> variance_population <- var(serie) * (n - 1) / n
> # Affichage de la valeur de la variance de la série statistique
> cat("La variance de la population est de : ", variance_population, "\n")
La variance de la population est de : 0.025744
>


```

## 2 Exercice 2 : Influence de l'alcool sur le temps de réaction

1. Tracer de la fonction de repartition empirique correspondant aux deux situations (utilisation de `simple plot()`)



1.1 Tracer de la fonction de repartition empirique correspondant aux deux situations (utilisation de `ggplot2()`)



## 2. Test d'hypothèse pour comparer les deux groupes

Il s'agit de montrer l'influence de l'alcool sur le temps de réaction au seuil de risque  $\alpha = 5\%$  soit un seuil de confiance de 95%. Pour ce faire on utilisera le test de student car les données sont distribuées dans chaque groupe.

```
sans_alcool <- c(0.68, 0.64, 0.68, 0.82, 0.58, 0.80, 0.72, 0.65, 0.84, 0.73,
                 0.65, 0.59, 0.78, 0.67, 0.65)

# Le vecteur avec_vecteur
avec_alcool <- c(0.73, 0.62, 0.66, 0.92, 0.68, 0.87, 0.77, 0.70, 0.88, 0.79,
                 0.72, 0.60, 0.78, 0.66, 0.68)
```

### 2.1. Formulation des hypothèses

- Hypothèse nulle ( $H_0$ ) pour p-value  $> 0.05$  : Les caractères sont normalement distribués (l'alcool n'a pas d'influence sur le temps de réaction.)

- Hypothèse alternative( $H_1$ ) pour p-value  $< 0.05$  : Les caractères ne sont pas normalement distribués (l'alcool a une influence sur le temps de réaction.)

2.2. Il s'agit de déterminer le risque à prendre pour tirer une conclusion erronée soit  $\alpha = 0.05$ .

2.3. Vérification des données

```
# Vérification de la normalité
shapiro_sans_alcool <- shapiro.test(sans_alcool)
shapiro_avec_alcool <- shapiro.test(avec_alcool)

cat("Le taux de normalité pour le groupe sans alcool")
```

Le taux de normalité pour le groupe sans alcool

```
shapiro_sans_alcool
```

Shapiro-Wilk normality test

```
data:  sans_alcool
W = 0.93536, p-value = 0.3275
```

```
cat("Le taux de normalité pour le groupe avec alcool")
```

Le taux de normalité pour le groupe avec alcool

```
shapiro_avec_alcool
```

Shapiro-Wilk normality test

```
data:  avec_alcool
W = 0.94482, p-value = 0.4468
```

Le test de Shapiro-Wilk montre que les deux groupes *avec alcool* et *sans alcool* suivent une distribution normale ( $p > 0.05$ ). Par conséquent l'hypothèse de normalité est respectée pour les deux échantillons.

2.4. Test d'égalité des variances : Déterminer s'il y'a une différence significative entre les variances.

```
var_test <- var.test(sans_alcool, avec_alcool)
cat("Test d'égalité des variances")
```

Test d'égalité des variances

```
print(var_test)
```

F test to compare two variances

```
data: sans_alcool and avec_alcool
F = 0.70037, num df = 14, denom df = 14, p-value = 0.5139
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
 0.2351348 2.0861120
sample estimates:
ratio of variances
      0.7003695
```

Dans notre cas on a  $p\text{-value} = 0.5139 > 0.05$ , il indique qu'il n'y a pas de différence significative entre les deux variances. On peut donc supposer l'égalité des variances entre les deux groupes.

## 2.5. Test de student

```
# Test de student pour les échantillons indépendants
test_t <- t.test(avec_alcool, sans_alcool, var.equal = TRUE)
cat("Test de student pour les échantillons")
```

Test de student pour les échantillons

```
print(test_t)
```

Two Sample t-test

```
data: avec_alcool and sans_alcool
t = 1.1923, df = 28, p-value = 0.2432
alternative hypothesis: true difference in means is not equal to 0
```

```
95 percent confidence interval:
-0.02776448  0.10509781
sample estimates:
mean of x mean of y
0.7373333  0.6986667
```

***Résultat du test de student :***

- Statistique t : **1.1923**
- Degré de liberté (n - 2) : **28**
- p-value : **0.2432**
- Intervalle de confiance à 95% : **[-0.02776448 ; 0.10509781]**
- Moyenne du groupe sans alcool : **0.6986667**
- Moyenne du groupe avec alcool : **0.7373333**

Les tests préliminaires de Shapiro–Wilk ont confirmé la normalité des distributions dans les deux groupes ( $p > 0.05$ ), et le test de Fisher a indiqué l'égalité des variances ( $p > 0.05$ ). Le test t de Student pour échantillons indépendants ( $t = 1.1923$ ,  $df = 28$ ,  $p = 0.2432$ ) ne montre aucune différence significative entre les moyennes du groupe avec alcool ( $M_{\text{avec alcool}} = 0.7373333$ ) et du groupe sans alcool ( $M_{\text{sans alcool}} = 0.6986667$ ). Ainsi, la consommation d'alcool ne semble pas avoir d'effet significatif sur la variable mesurée dans cet échantillon.

Par conséquent l'hypothèse  $H_0$  est vérifiée. L'alcool n'a pas d'influence significative sur le temps de réaction.

### ***3 Exercice 3 : Analyse de données pour enfant***

1. Création des vecteur

```
# Création des vecteurs

#vecteurs individus
Individus = c("Erika", "Célia", "Erik", "Eve", "Paul", "jean", "Adan", "Louis",
              "Jules", "Léo")

#vecteurs Poids
Poids = c(16, 14, 13.5, 15.4, 16.5, 16, 17, 14.8, 17, 16.7)

#vecteurs Taille
Taille = c(100.0, 97.0, 95.5, 101.0, 100.0, 98.5, 103.0, 98.0, 101.5, 100.0)
```



```
#vecteurs sexe
Sexe = c("F", "F", "G", "F", "G", "G", "G", "G", "G", "G")
```

### 1.1. Vecteur pour calculer l'âge des individus

```
# Vecteur An
An <- c(3, 3, 3, 4, 3, 4, 3, 3, 4, 3)
# length(An)
# Vecteur Mois

Mois <- c(5, 10, 5, 0, 8, 0, 11, 9, 1, 3)
# length(Mois)
# Calculer l'âge des individus

Age <- round(An + Mois/12, 1)
# Age
```

### 2. La moyenne des variables (variables quantitatives)

```
#moyenne de la taille
moyenne_taille <- mean(Taille)
moyenne_poids <- mean(Poids)
moyenne_age <- mean(Age)

# Affichage des moyennes
cat("La moyenne des tailles : ", moyenne_taille, "cm\n")
```

La moyenne des tailles : 99.45 cm

```
cat("La moyenne des poids : ", moyenne_poids, "kg\n")
```

La moyenne des poids : 15.69 kg

```
cat("La moyenne des âges : ", moyenne_age, "an(s)\n")
```

La moyenne des âges : 3.73 an(s)

### 3. Calcul de l'indice de masse corporelle (IMC)

```
# Taille en mètre
taille_m <- Taille / 100

# Calcul de l'IMC
IMC_echantillon = round((Poids / (taille_m)^2), 2)
# IMC_echantillon

cat("Valeur de l'IMC: \n")
```

Valeur de l'IMC:

```
for (i in 1:length(Individus)) {
  cat(Individus[i], " : " ,IMC_echantillon[i], "kg/m²\n")
}
```

```
Erika : 16 kg/m²
Célia : 14.88 kg/m²
Erik : 14.8 kg/m²
Eve : 15.1 kg/m²
Paul : 16.5 kg/m²
jean : 16.49 kg/m²
Adan : 16.02 kg/m²
Louis : 15.41 kg/m²
Jules : 16.5 kg/m²
Léo : 16.7 kg/m²
```

#### 4. Structure en dataframe

```
enfant_df <- data.frame(
  Individus = Individus,
  Sexe = Sexe,
  Poids = Poids,
  Taille = Taille,
  Age_complet = Age,
  IMC_echantillon = IMC_echantillon
)

enfant_df
```

```
Individus Sexe Poids Taille Age_complet IMC_echantillon
```

1	Erika	F	16.0	100.0	3.4	16.00
2	Célia	F	14.0	97.0	3.8	14.88
3	Erik	G	13.5	95.5	3.4	14.80
4	Eve	F	15.4	101.0	4.0	15.10
5	Paul	G	16.5	100.0	3.7	16.50
6	jean	G	16.0	98.5	4.0	16.49
7	Adan	G	17.0	103.0	3.9	16.02
8	Louis	G	14.8	98.0	3.8	15.41
9	Jules	G	17.0	101.5	4.1	16.50
10	Léo	G	16.7	100.0	3.2	16.70

5. Obtenir les informations sur la fonction `plot()`

```
# Informations sur la fonction plot()
?plot()
```

démarrage du serveur d'aide `httpd ... fini`

6. Nuage de points du Poids en fonction de la taille

6.1 Installation du package de `plotly`

```
# Installation de plotly()
# install.packages("plotly")
# Chargement du package
library(plotly)
install.packages("webshot2")
```

6.2 Calcul du coefficient de corrélation

```
# Coefficient de corrélation entre le Poids et la taille
correlation <- cor(Taille, Poids)
cat("Le coefficient de corrélation entre la taille et le poids est de : ",
    round(correlation, 3))
```

Le coefficient de corrélation entre la taille et le poids est de : 0.878

6.3 Création du graphique

```

# Ajout de la droite de régression
plot <- plot %>%
  add_trace(
    x = ~Taille,
    y = ~fitted(lm(Poids ~ Taille, data = enfant_df)),
    type = 'scatter',
    mode = 'lines',
    name = "Régression linéaire",
    line = list(color = "red", width = 3, dash = "solid"),
    showlegend = FALSE
  ) %>%
  layout(
    title = list(
      text = '<br><b>Relation Poids-Taille par Sexe</b></br>',
      x = 0.5,
      font = list(size = 18)
    ),
    xaxis = list(
      title = 'Taille (cm)',
      zeroline = FALSE,
      gridcolor = 'lightgrey'
    ),
    yaxis = list(
      title = 'Poids (kg)',
      zeroline = FALSE,
      gridcolor = 'lightgrey'
    ),
    plot_bgcolor = 'white',
    legend = list(x = 0.02, y = 0.98),
    annotations = list(
      list(
        x = 0.02, y = 0.02,
        xref = "paper", yref = "paper",
        text = paste("r =", round(correlation, 3)),
        showarrow = FALSE,
        font = list(size = 14, color = "black"),
        bgcolor = "lightyellow",
        bordercolor = "orange"
      )
    )
  )
)

```

```
# Affichage du graphique  
plot
```

Sortie du code

